Feature Store, Triton, архитектура

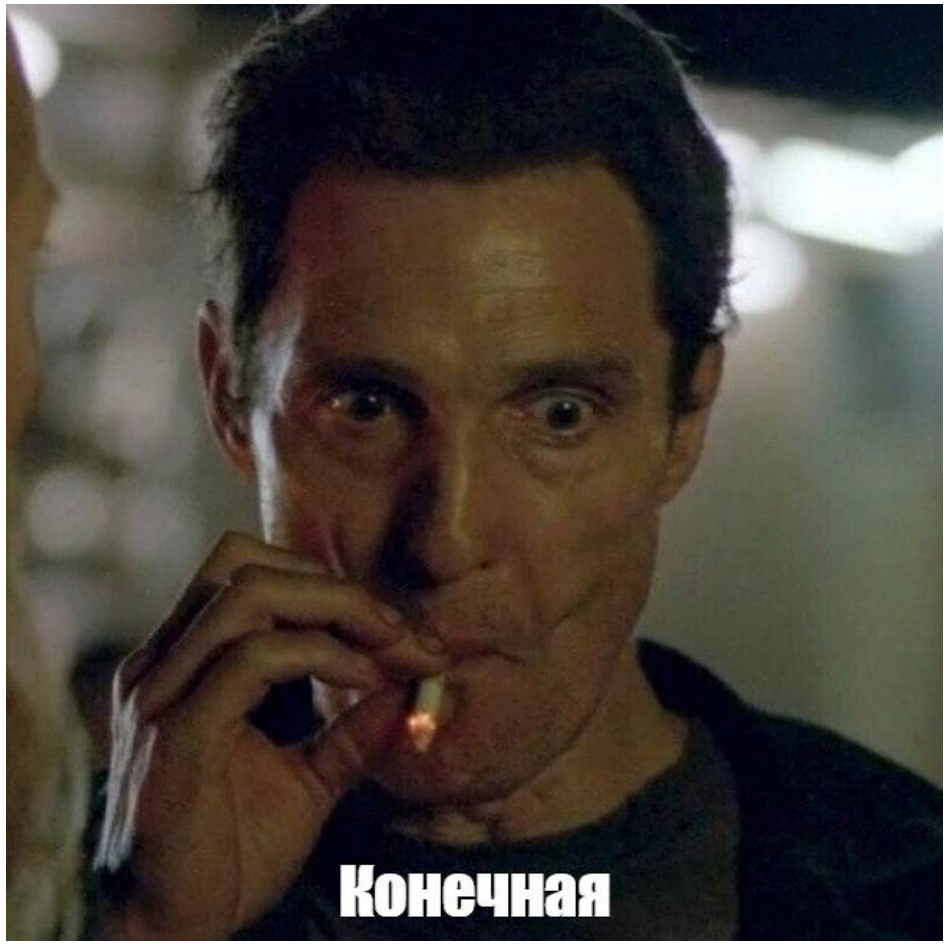

Борисенко Глеб

19.12.2024

Конечная ☹

Feature Store

Еще картинка

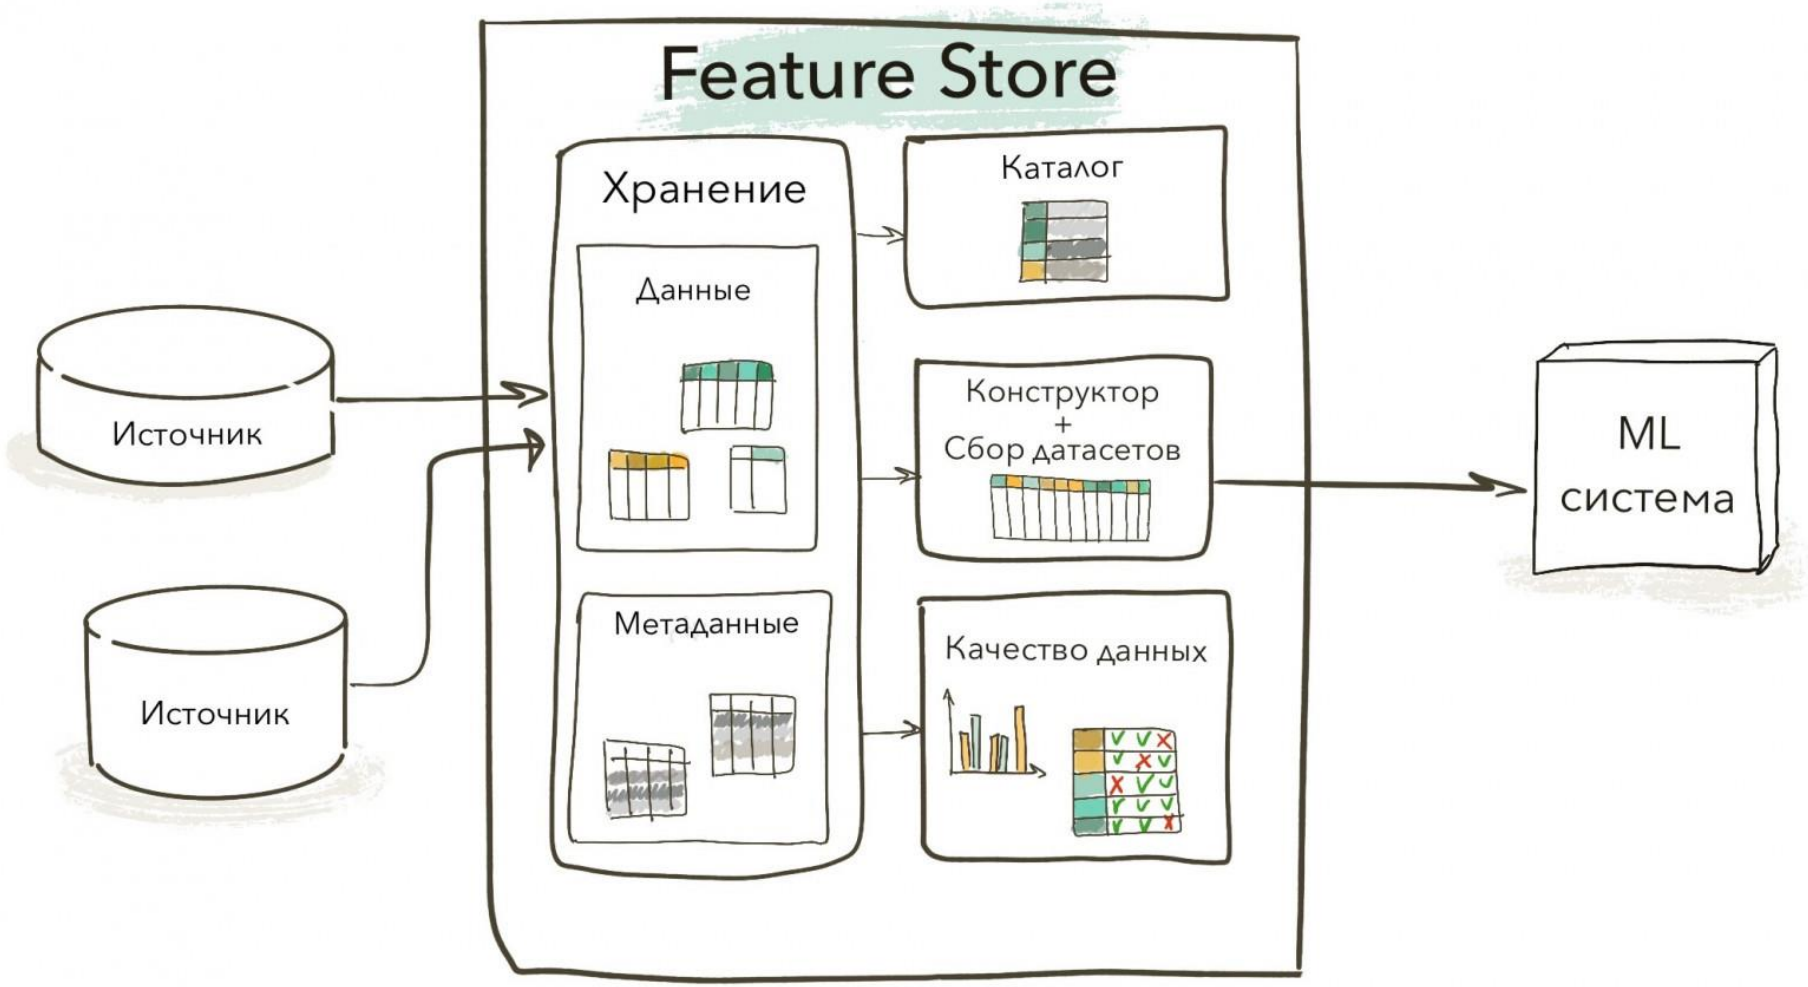

Что за предагрегат?

- Фичи по возможности хранятся в максимально атомарном виде.
- Фичи сгруппированы с некоторой минимально-необходимой гранулярностью: данные агрегируются за день/неделю/месяц.

Feast

- Feast is likely not the right tool if you:
  - are in an organization that's just getting started with ML and is not yet sure what the business impact of ML is
  - Rely primarily on unstructured data
  - need very low latency feature retrieval (e.g. p99 feature retrieval << 10ms)
  - have a small team to support a large number of use cases

Концепты Feast

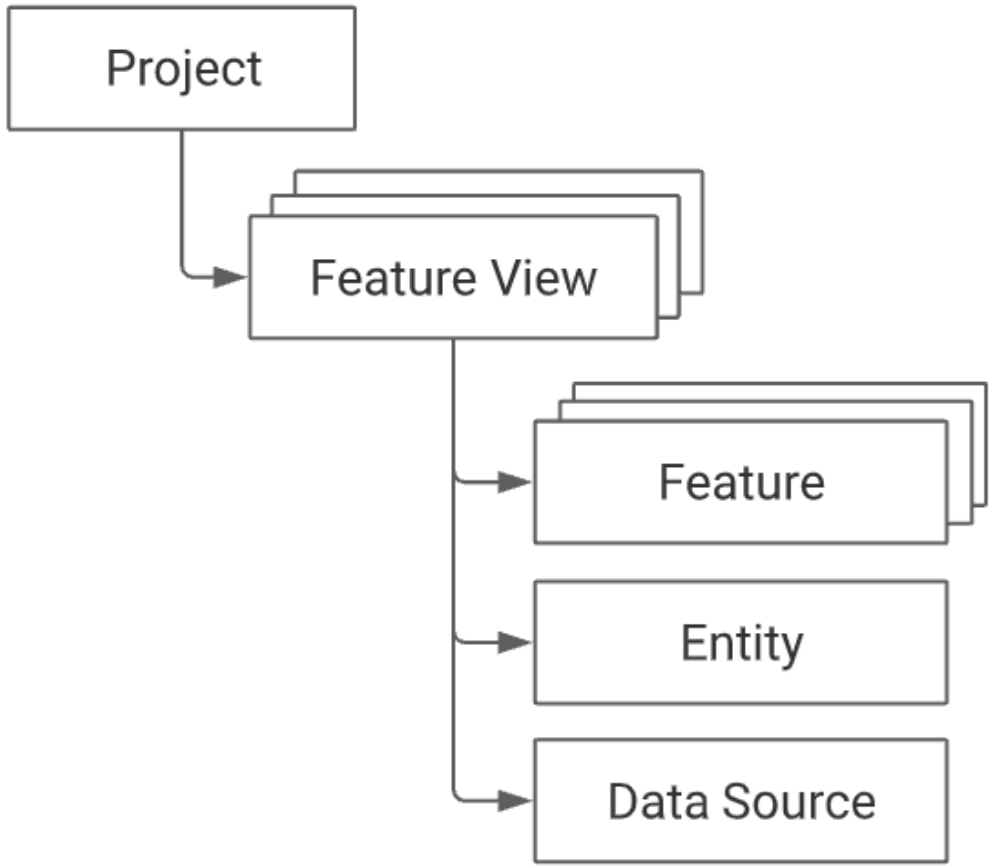

Entity

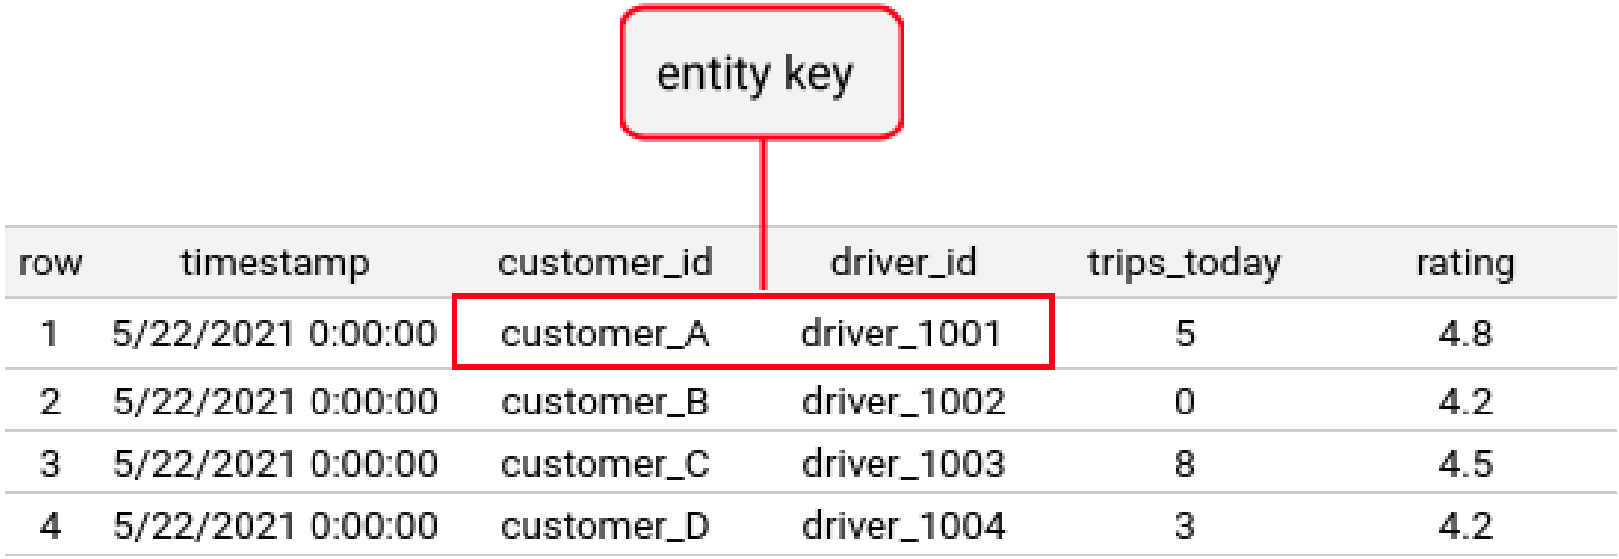

row	timestamp	customer_id	driver_id	trips_today	rating
1	5/22/2021 0:00:00	customer_A	driver_1001	5	4.8
2	5/22/2021 0:00:00	customer_B	driver_1002	0	4.2
3	5/22/2021 0:00:00	customer_C	driver_1003	8	4.5
4	5/22/2021 0:00:00	customer_D	driver_1004	3	4.2

Feature View

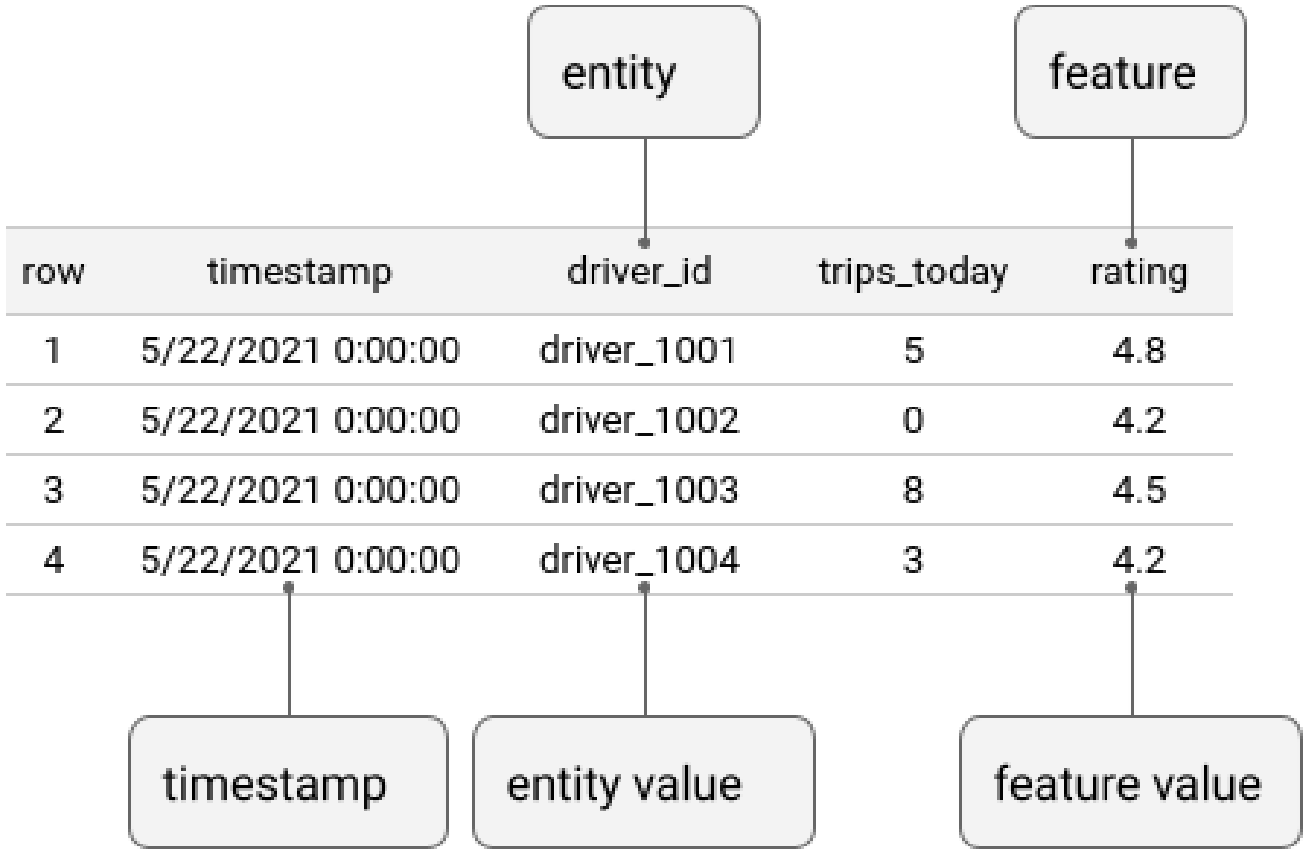

Feature View

```
from feast import BigQuerySource, Entity, FeatureView, Field
from feast.types import Float32, Int64

driver = Entity(name="driver", join_keys=["driver_id"])

driver_stats_fv = FeatureView(
    name="driver_activity",
    entities=[driver],
    schema=[
        Field(name="trips_today", dtype=Int64),
        Field(name="rating", dtype=Float32),
    ],
    source=BigQuerySource(
        table="feast-oss.demo_data.driver_activity"
    )
)
```

Опять картинка

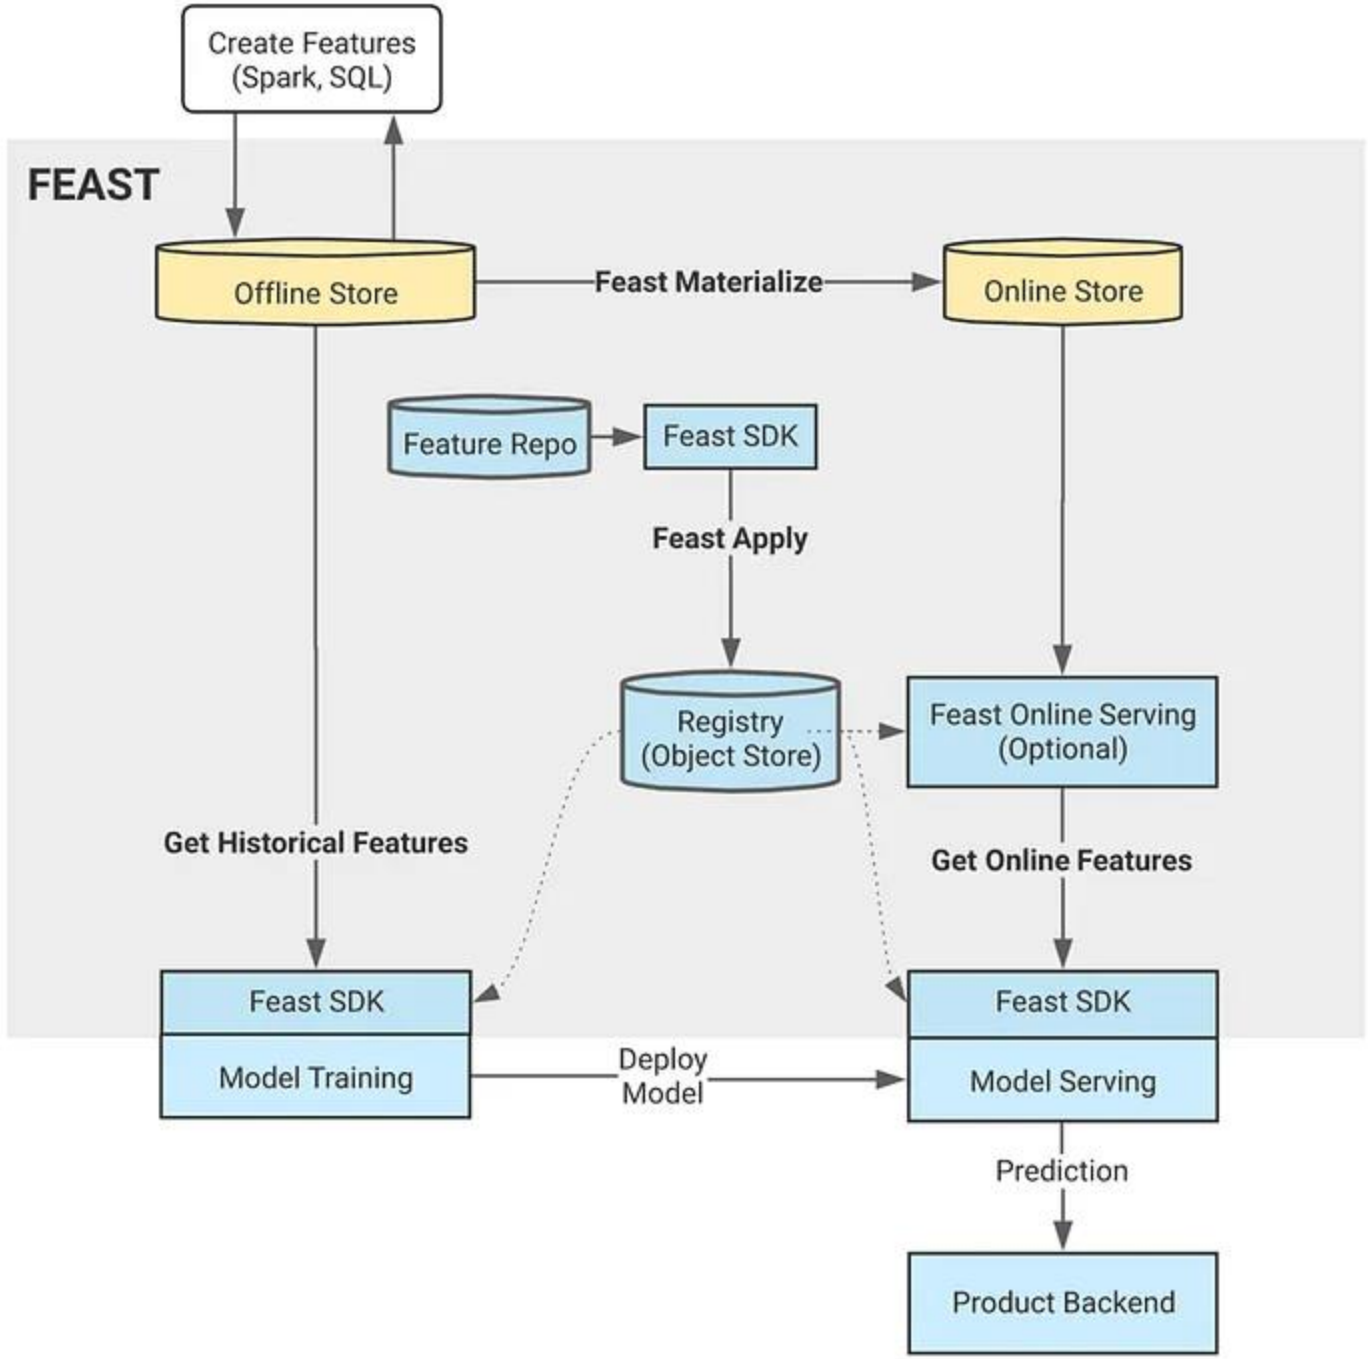

Feature Service и получение фичей

```
from driver_ratings_feature_view import driver_ratings_fv
from driver_trips_feature_view import driver_stats_fv

driver_stats_fs = FeatureService(
    name="driver_activity",
    features=[driver_stats_fv, driver_ratings_fv[["lifetime_rating"]]]
)
```

```
from feast import FeatureStore
feature_store = FeatureStore('.')  # Initialize the feature store

feature_service = feature_store.get_feature_service("driver_activity")
feature_store.get_historical_features(features=feature_service, entity_df=entity_df)
```

Прямое получение фичей

```
entity_df = pd.DataFrame.from_dict(
    {
        "driver_id": [1001, 1002, 1003, 1004, 1001],
        "event_timestamp": [
            datetime(2021, 4, 12, 10, 59, 42),
            datetime(2021, 4, 12, 8, 12, 10),
            datetime(2021, 4, 12, 16, 40, 26),
            datetime(2021, 4, 12, 15, 1, 12),
            datetime.now()
        ]
    }
)
training_df = store.get_historical_features(
    entity_df=entity_df,
    features=store.get_feature_service("model_v1"),
).to_df()
print(training_df.head())
```

Triton Inference Server

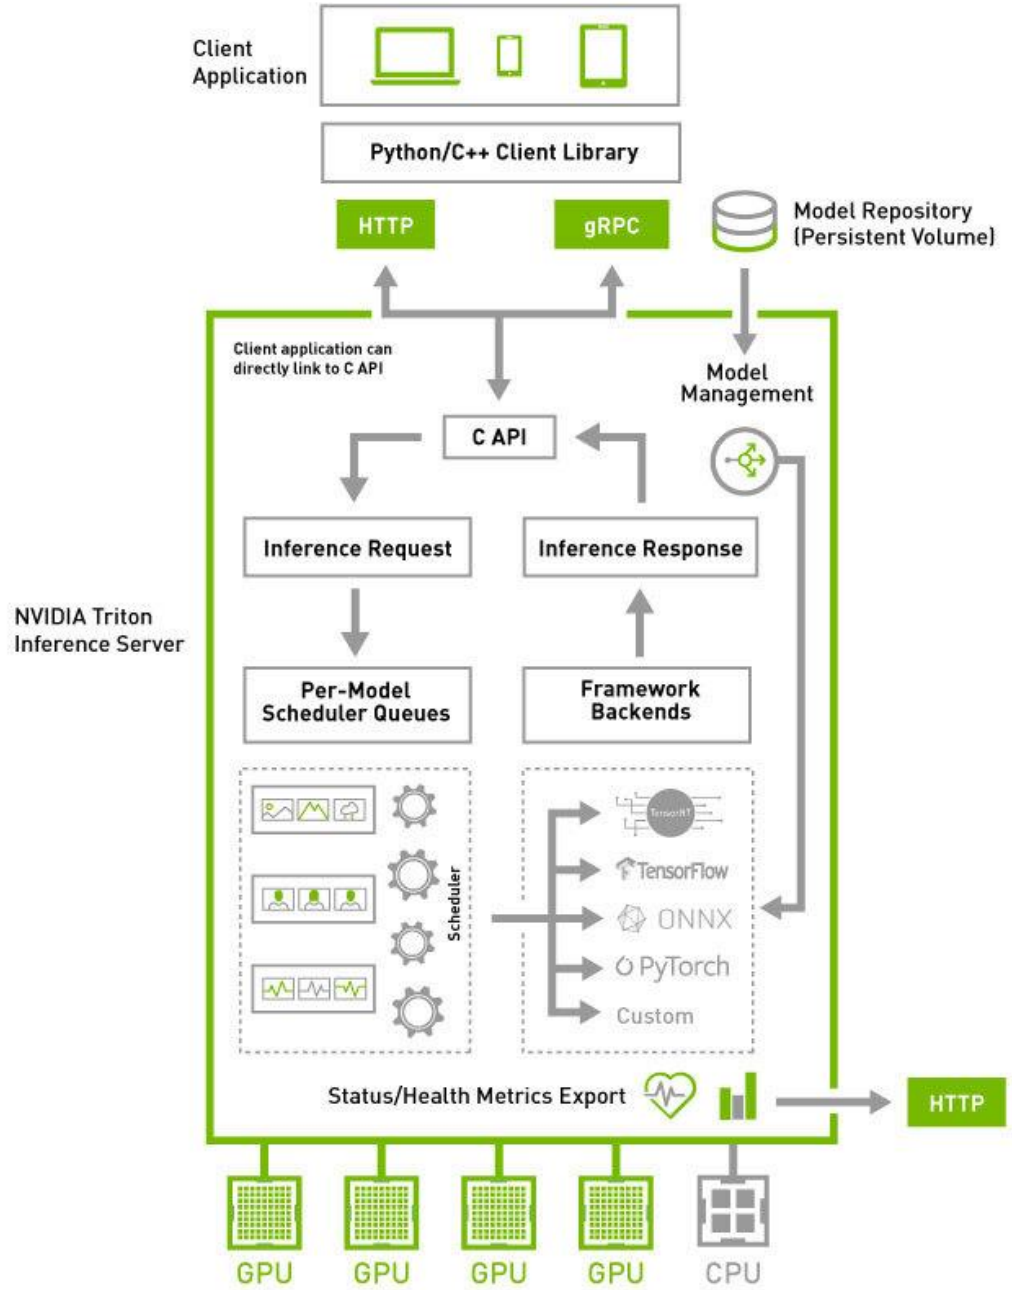

Фичи

- Параллельный запуск моделей
- Поддержка кучи фреймворков
- Динамические батчи
- Некоторые бэкэнды освобождают память, когда не используются
- Есть последовательные батчи
- Сервисы (модели) могут быть Stateful

Конфиг модели torchscript

```
backend: "pytorch"
max_batch_size: 32
input [
    {
        name: "input__0"
        data_type: TYPE_FP32
        dims: [ 3, 24, 94 ]
    }
]
output [
    {
        name: "output__0"
        data_type: TYPE_FP32
        dims: [ 3, 24, 94 ]
    }
]
```

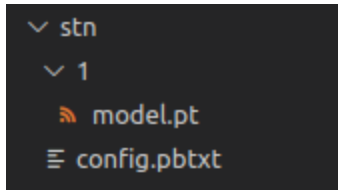

Python backend

```python
def initialize(self, args):
    self.model_config = json.loads(args["model_config"])
    self.model = load_yolo(
        settings.YOLO.WEIGHTS, settings.YOLO.CONFIDENCE, torch.device("cuda")
    )
```

```
backend: "python"
max_batch_size: 0
input [
    {
        name: "input__0"
        data_type: TYPE_UINT8
        dims: [ -1, -1, 3 ]
    }
]
output [
    {
        name: "output__0"
        data_type: TYPE_FP32
        dims: [ -1, 3, 24, 94 ]
    },
    {
        name: "output__1"
        data_type: TYPE_FP32
        dims: [ -1, 4 ]
    }
]
```

```python
def execute(
    self, requests: List[pb_utils.InferenceRequest]
) -> List[pb_utils.InferenceRequest]:

    responses = []

    for request in requests:
        image = pb_utils.get_input_tensor_by_name(request, "input__0").as_numpy()
        image = prepare_detection_input(image)

        detection = self.model(image, size=settings.YOLO.PREDICT_SIZE)

        df_results = detection.pandas().xyxy[0]
        img_plates = prepare_recognition_input(
            df_results, image, return_torch=False
        )

        out_tensor_0 = pb_utils.Tensor(
            "output__0", img_plates.astype(self.output0_dtype)
        )
        out_tensor_1 = pb_utils.Tensor(
            "output__1",
            df_results[["xmin", "ymin", "xmax", "ymax"]]
            .to_numpy()
            .astype(self.output1_dtype),
        )

        inference_response = pb_utils.InferenceResponse(
            output_tensors=[out_tensor_0, out_tensor_1]
        )
        responses.append(inference_response)

    return responses
```

Граф вычислений

```
cropped_images, coordinates = self.predict(
    model_name="yolo",
    ...
)

num_plates = from_dlpack(coordinates.to_dlpack()).shape[0]
if num_plates == 0:
    ...
    continue

(plate_features,) = self.predict(
    model_name="stn",
    ...
)

(text_features,) = self.predict(
    model_name="lprnet",
    ...
)
```

```
backend: "python"
max_batch_size: 0
input [
    {
        name: "input__0"
        data_type: TYPE_UINT8
        dims: [ -1, -1, 3 ]
    }
]
output [
    {
        name: "coordinates"
        data_type: TYPE_FP32
        dims: [ -1, 4 ]
    },
    {
        name: "texts"
        data_type: TYPE_STRING
        dims: [ -1, 1 ]
    }
]
```

Вы успешны

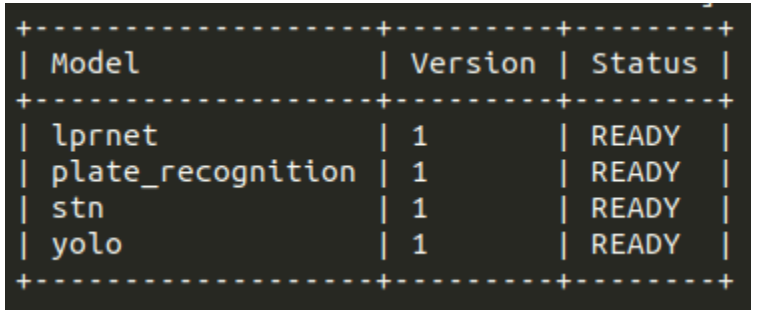

Model	Version	Status
lprnet	1	READY
plate_recognition	1	READY
stn	1	READY
yolo	1	READY

Архитектура

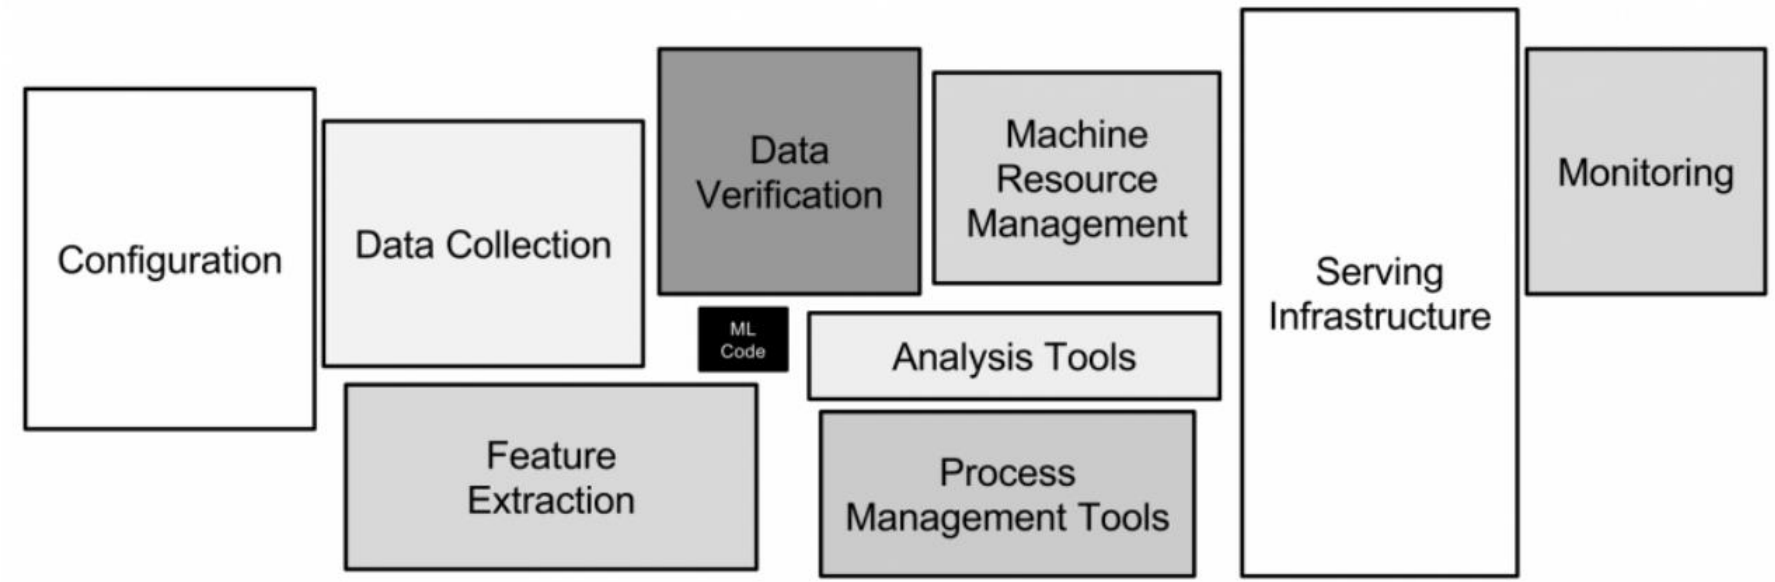

Все это вместе образует **Систему**.

Архитектура - это устройство таких систем.

Зачем нам думать об этом?

0. Архитектура описывает конечный предмет, который мы должны построить
1. Выбор архитектуры диктует слабые и сильные стороны решения и пути его модификации в будущем
2. Плохая архитектура породит технический долг и приведет к проблемам в её работе, поддержке, и доработке
3. Для эффективной работы в команде нужно общее понимание, как именно устроена ваша система

Best Practices for ML Engineering by Martin Zinkevich

- To make great products: **do machine learning like the great engineer you are, not like the great machine learning expert you aren’t .**

От требований к архитектуре

- Требования к расчету фичей
  - на лету или предварительно?
  - с помощью каких программных средств?
- Требования к обучению
  - как часто?
  - на каких ресурсах?
- Требования к выдаче прогнозов
  - каким способом?
  - как быстро?
  - минимальное допустимое качество?
- Tradeoff скорость/надежность разработки
- Требования к автономности
- Требования к доступной кастомизации
- Требования к обработке приватных данных

И прочее, прочее, прочее

Препроцессинг фичей

- Обычно есть два подхода:
  - Считаем фичи в режиме реального времени
  - Требуется рассчитывать некоторые фичи заранее
- Использование имеющихся источников порождает задачи интеграции и накладывает на них ограничения - например, по времени ответа.
- Feature Store здесь очень помогает

Обучение

- Наиболее распространено переобучение по расписанию - запускаем код с помощью cronjob, планировщиков задач
- Еще вариант – обучение на лету (например, с помощью Kafka, Flint)

Выдача прогнозов - сервис

- Как сервис:
  - Просто: Пишем REST API обертку на питоне
  - Быстро: Переписываем код на Go/C++, используем gRPC
- Как зависимость
- С Precompution-ом
- По требованию (через брокер и очереди)

Когда ML - дополнение

- Часто ML-системы возникают не на пустом месте, а поверх уже
- существующей инфраструктуры:
  - 1. Уже есть Data Warehouse
  - 2. Уже есть бэкенд и устоявшиеся подходы к разработке
- В таком случае типично использование имеющихся инструментов и подходов.
- Пример - использование Airflow для запуска пайплайнов по обучению моделей, когда он используется в компании для ETL.
- Или деплой на AWS Sagemaker/OpenShift/Heroku, когда они используются разработчиками, и так далее.
- Это может быть как плохо (бывают неудобные инструменты), так и хорошо (не нужно возводить все с нуля).

Итак

- Архитектура - это описание и устройство программных систем
- Начинать разговор об архитектуре удобно с набора требований к системе. Одни из основных ML-специфичных - это требования к расчету фичей, к обучению моделей и к выдаче прогнозов.

MLOps пайплайн (назад в прошлое)

MLOps level 0: Manual process

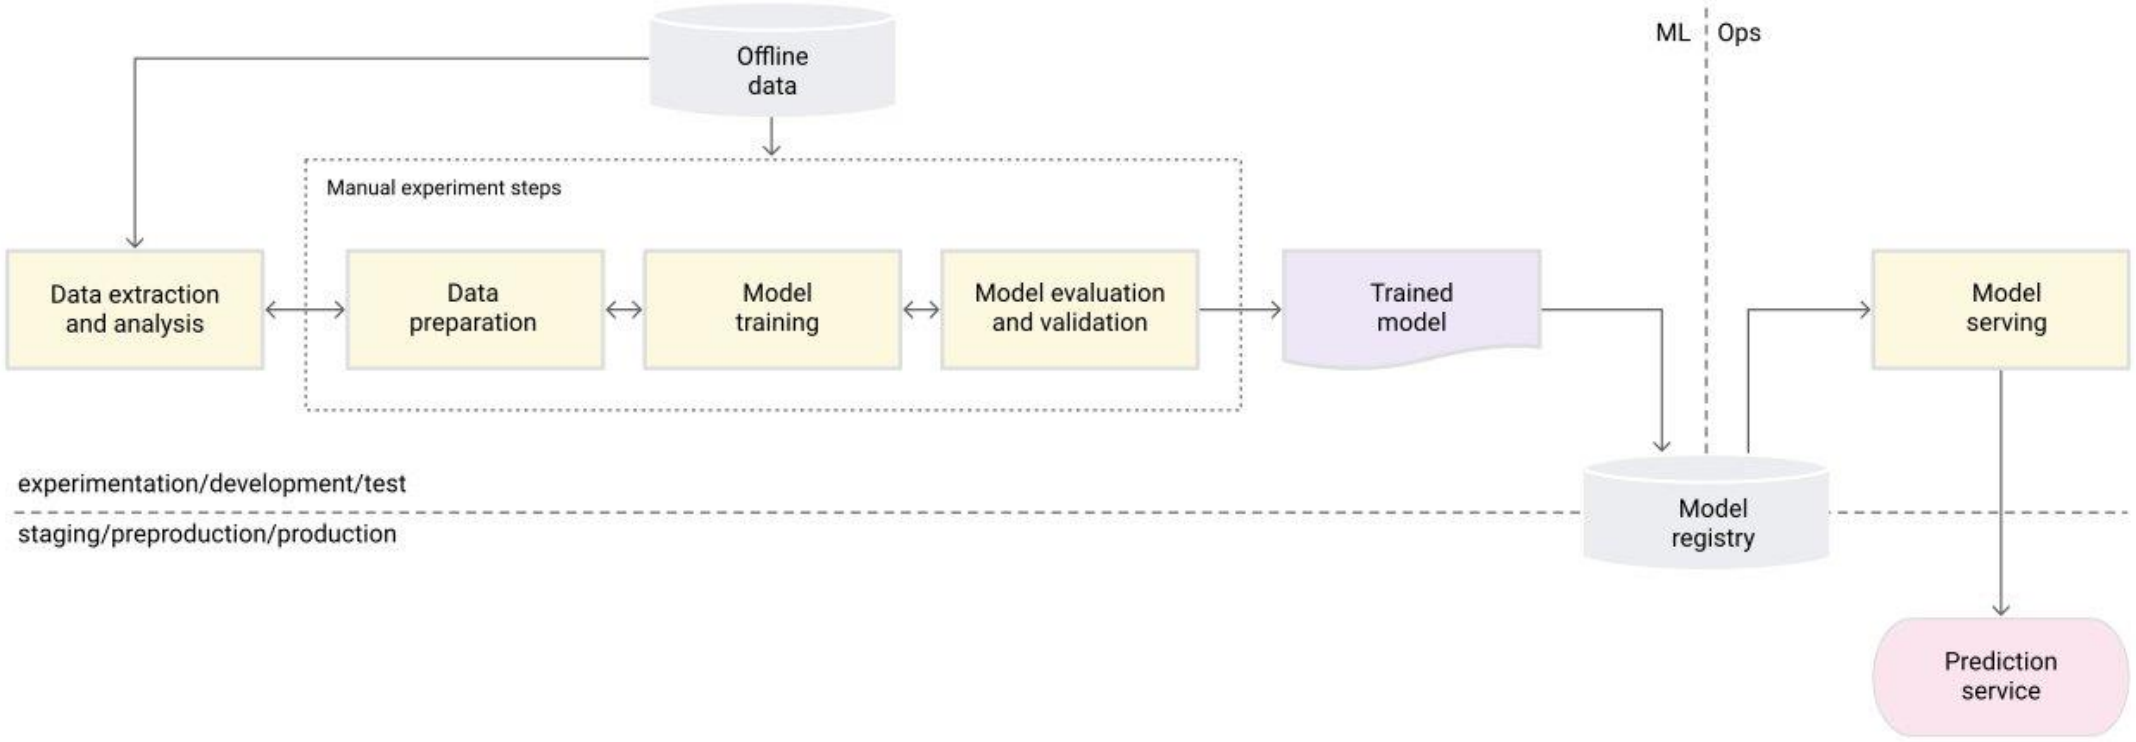

MLOps Level 1: автоматизация ML пайплайна

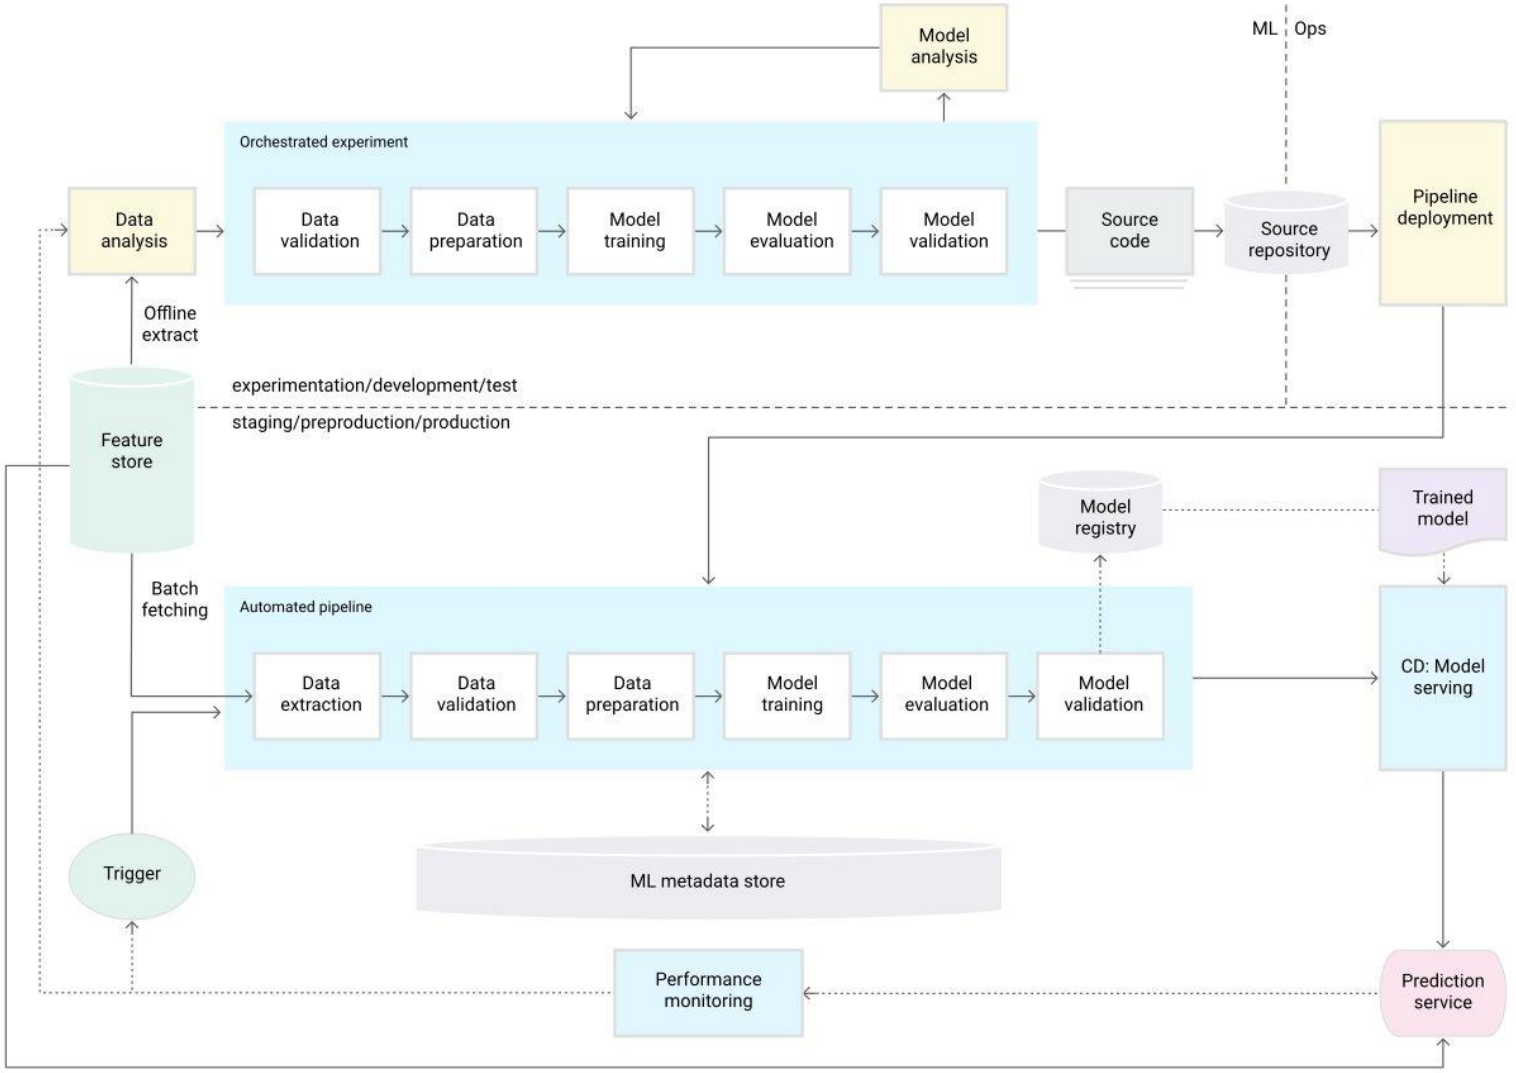

MLOps Level 2: автоматизация CI/CD пайплайна

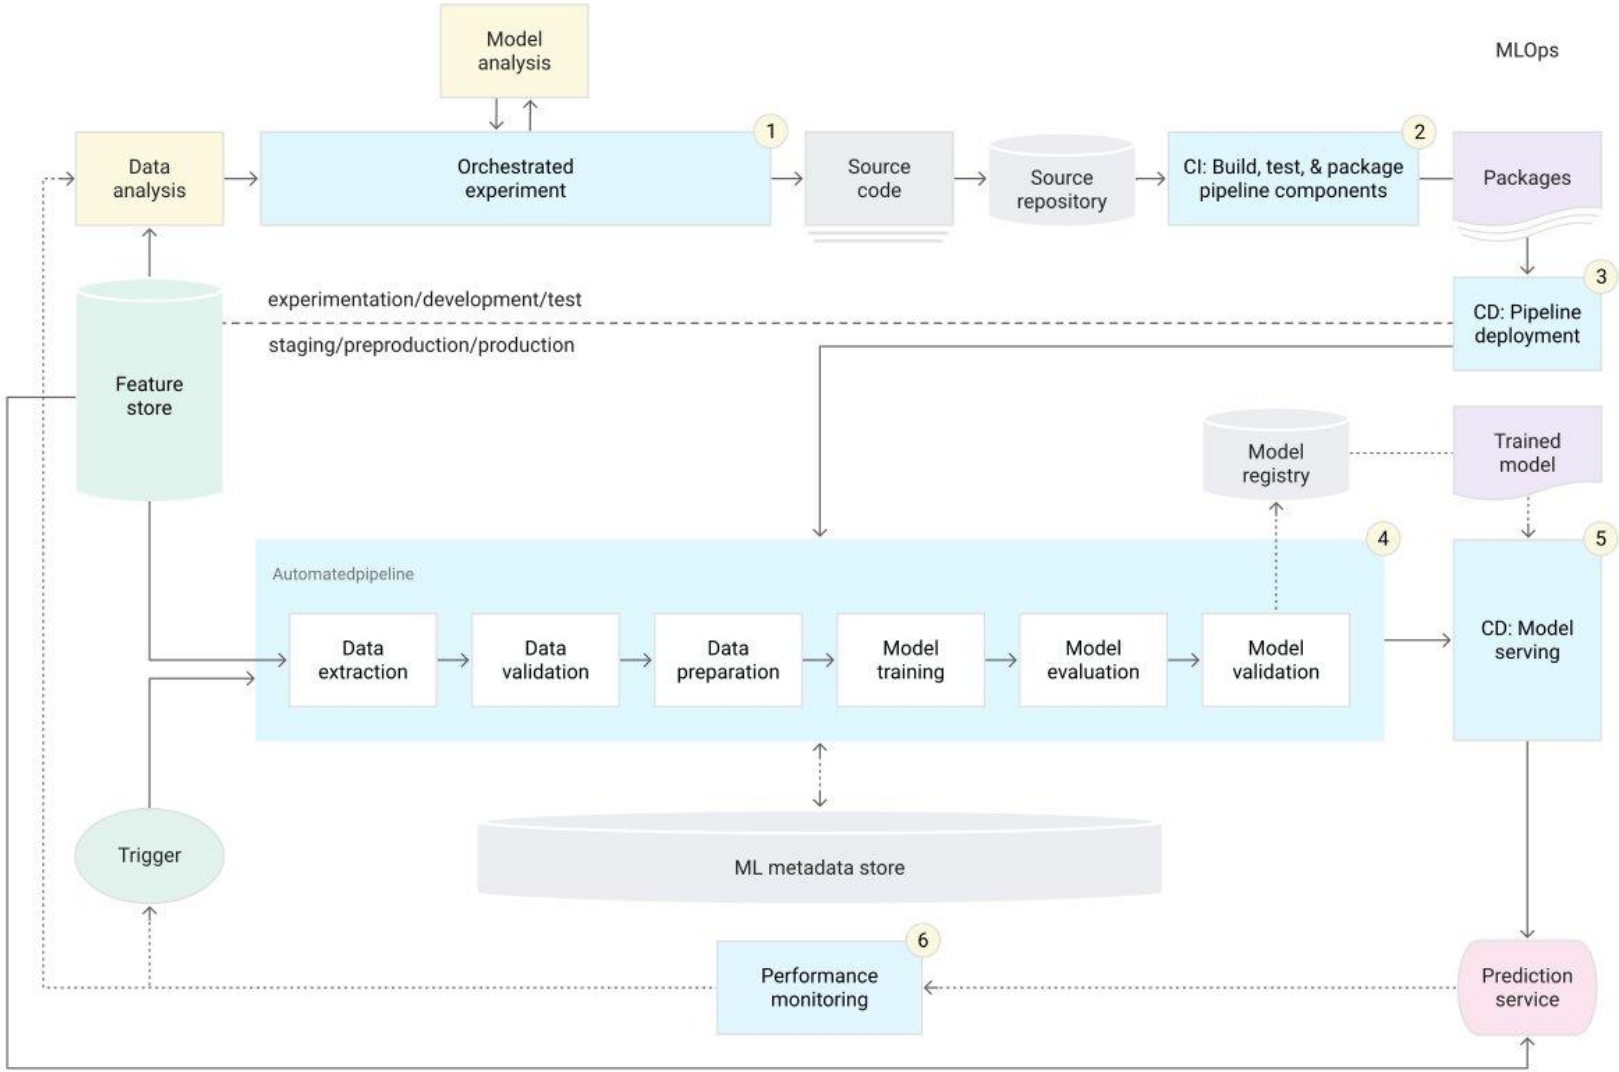

Спасибо вам за ваше внимание и интерес на курсе :)

- Спасибо, что слушали :3
- Домашки обязательно тщательно допроверяю в ближайшее время, что у вас было достаточно времени для их правки
- Ооочень жду комментариев, критики, оценки от вас (можно и желательно в личку в телеге, не стесняйтесь писать правду :D)
- Еще раз спасибо :3